Universidad Yachay Tech
Maestría en Ciencia de Datos

Diseño de Arquitectura de Datos para un E-Commerce

High Level Design (HLD) – Yachay-Shop

Taller 04 – Arquitectura de Datos

13 de octubre de 2026

Índice

1. Resumen ejecutivo **3**

2. Contexto y requerimientos **3**

2.1. Fuentes de datos . . . 3

2.2. Desafíos . . . 4

2.3. Requerimientos no funcionales . . . 4

3. Decisión: Data Warehouse, Data Lake o ambos **4**

4. Arquitectura de alto nivel **5**

5. Métodos de ingestión por fuente **6**

6. Transformación y unificación de datos **7**

6.1. Pasos de transformación Bronze → Silver . . . 8

6.2. Resolución de identidad (Vista 360) . . . 8

6.3. Herramientas . . . 8

7. Almacenamiento y modelo de datos **9**

7.1. Almacenamiento según tipo de dato . . . 9

7.2. Organización física . . . 9

7.3. Modelo dimensional de la capa Gold . . . 9

8. Procesamiento batch y en tiempo real **10**

8.1. Camino en tiempo real (*hot path*) . . . 10

8.2. Camino batch (*cold path*) . . . 11

9. Consumo: BI, reportes y analítica predictiva **11**

9.1. Eficacia del marketing . . . 12

9.2. Pronósticos y analítica predictiva . . . 12

10. Gobierno, seguridad, calidad y observabilidad **12**

11. Escalabilidad **13**

12. Trazabilidad, implementación y conclusiones **14**

12.1. Necesidades del negocio frente a componentes . . . 14

12.2. Hoja de ruta sugerida . . . 14

12.3. Riesgos y mitigación . . . 15

12.4. Conclusiones 15

1. Resumen ejecutivo

Se propone una arquitectura **Lakehouse con modelo *medallion* (Bronze, Silver, Gold)**, alimentada por dos caminos de ingestión: **streaming** (eventos y CDC sobre un bus Kafka) para inventario y comportamiento en tiempo real, y **batch** (cargas programadas y APIs) para CRM y marketing externo. Un único almacenamiento en formato abierto (Delta Lake sobre *object storage*) elimina los silos y sirve tanto a BI como a ciencia de datos.

El diseño resuelve las cuatro necesidades del negocio:

- **Vista 360 del cliente**: resolución de identidad (MDM) que une web, app, POS y CRM en un `golden_customer_id`.
- **Inventario en tiempo real**: CDC del sistema de inventarios y eventos POS procesados en segundos y publicados a web, app y tiendas mediante una caché/API de disponibilidad.
- **Eficacia del marketing**: datos de Google Analytics y Facebook Ads vinculados a ventas por campaña, UTM y cliente para medir ROAS y atribución.
- **Reportes y pronósticos**: *marts* dimensionales en la capa Gold, consumidos por Power BI (diario, semanal, mensual) y por modelos de ML de pronóstico de demanda.

Alcance. Este HLD define componentes, flujos, almacenamiento, procesamiento, consumo, gobierno y escalabilidad. No cubre el diseño detallado (LLD) de esquemas físicos, código de *pipelines* ni dimensionamiento exacto de infraestructura.

Stack de referencia. El diseño es agnóstico de proveedor; como implementación de referencia se usan componentes estándar de la industria: Apache Kafka + Debezium (ingestión), Apache Spark / Flink (procesamiento), Delta Lake (almacenamiento), Airflow + dbt (orquestación y transformación), Unity Catalog (gobierno) y Power BI (visualización). Cada pieza tiene un equivalente gestionado en Azure, AWS o GCP.

2. Contexto y requerimientos

Yachay-Shop opera cinco sistemas aislados que generan datos con formatos, frecuencias y latencias distintas; la arquitectura debe absorber esa variedad sin forzar un único patrón de ingestión.

2.1 Fuentes de datos

Tabla 1: Inventario de fuentes de datos

Fuente	Datos que genera	Tipo de dato	Frecuencia	Latencia
Sitio web y app móvil	Clickstream (clics, tiempo en página, productos vistos), pedidos online, perfiles	Semiestructurado (JSON) y estructurado	Continua, alto volumen	Segundos
Tiendas físicas (POS)	Transacciones, movimientos de inventario, uso de tarjeta de fidelización	Estructurado	Continua en horario de tienda	Segundos a minutos
CRM	Perfiles de cliente, historial de pedidos, campañas	Estructurado	Cambios diarios	Horas
Gestión de inventarios	Existencias por almacén y tienda	Estructurado	Continua	Segundos

Fuente	Datos que genera	Tipo de dato	Frecuencia	Latencia
Marketing externo (GA4, Facebook Ads)	Impresiones, clics, costo, conversiones por campaña	Semiestructurado (JSON vía API)	Diaria u horaria	Horas

Además existen datos **no estructurados** relevantes: reseñas y comentarios de productos, imágenes de catálogo, tickets de servicio al cliente y logs de aplicación.

2.2 Desafíos

- **Silos de datos**: cada sistema tiene su propio identificador de cliente y producto; no existe una visión unificada.
- **Volumen y variedad**: mezcla de tablas transaccionales, eventos JSON, métricas de APIs y texto/imágenes.
- **Tiempo real**: inventario y compromiso del cliente deben reflejarse en segundos, sobre todo en ventas flash y campañas, cuando el tráfico puede multiplicarse varias veces.

2.3 Requerimientos no funcionales

Tabla 2: Objetivos de diseño propuestos

Requerimiento	Objetivo de diseño
Latencia de inventario	Disponibilidad actualizada en todos los canales en menos de 5 segundos
Frescura de reportes	Datos del día anterior disponibles antes de las 06:00
Escalabilidad	Escalar horizontalmente ante picos de ventas flash sin rediseño
Disponibilidad	99,9 % para el camino de inventario en tiempo real
Seguridad y cumplimiento	Datos personales protegidos (cifrado, enmascaramiento, control de acceso), alineado con la LOPDP de Ecuador
Reprocesamiento	Capacidad de recalcular históricos desde los datos crudos

Los valores numéricos de esta tabla son objetivos propuestos para el diseño, no métricas dadas por el enunciado.

3. Decisión: Data Warehouse, Data Lake o ambos

Decisión: una combinación de ambos, implementada como Lakehouse. Un *data lake* sobre *object storage* guarda todos los datos (estructurados, semiestructurados y no estructurados) a bajo costo, y una capa de tablas transaccionales (Delta Lake) le añade las garantías de un *warehouse*: ACID, esquemas, versionado y SQL de alto rendimiento.

Tabla 3: Comparación de alternativas de almacenamiento

Criterio	**Data Warehouse**	**Data Lake**	**Lakehouse (elegido)**
Tipos de datos	Solo estructurados	Todos	Todos
Costo por TB	Alto	Bajo	Bajo (object storage)
Calidad y ACID	Sí	No (riesgo de *data swamp*)	Sí (Delta / Iceberg)
Rendimiento BI	Alto	Bajo sin capa adicional	Alto (tablas Gold optimizadas, caché, Z-order)
Machine learning	Limitado	Bueno	Bueno, sobre los mismos datos
Streaming	Limitado	Posible	Nativo
Reprocesamiento	Difícil	Sí	Sí, con *time travel*

Justificación para Yachay-Shop:

1. La variedad de datos (clickstream JSON, reseñas, imágenes) descarta un *warehouse* puro.
2. Los reportes financieros y de ventas exigen calidad y consistencia, que un *lake* puro no garantiza.
3. Una sola copia de los datos sirve a BI y a ML, evitando duplicar *pipelines* entre un *lake* y un *warehouse* separados.
4. El formato abierto (Parquet + Delta) evita dependencia de un proveedor y separa almacenamiento de cómputo para escalar cada uno por su cuenta.

Alternativa aceptable: si la empresa ya cuenta con un *warehouse* gestionado (Snowflake, BigQuery, Synapse), puede usarse como capa de servicio de la zona Gold, manteniendo el *lake* como fuente única de Bronze y Silver.

4. Arquitectura de alto nivel

La Figura 1 muestra la arquitectura propuesta. La línea naranja es el **camino en tiempo real**: eventos y CDC pasan por Kafka y el procesamiento streaming directamente a la API de inventario y al dashboard operativo, y a la vez se persisten en Bronze. El resto de los datos se refina por Bronze, Silver y Gold antes de llegar a BI, ML y *reverse ETL*.

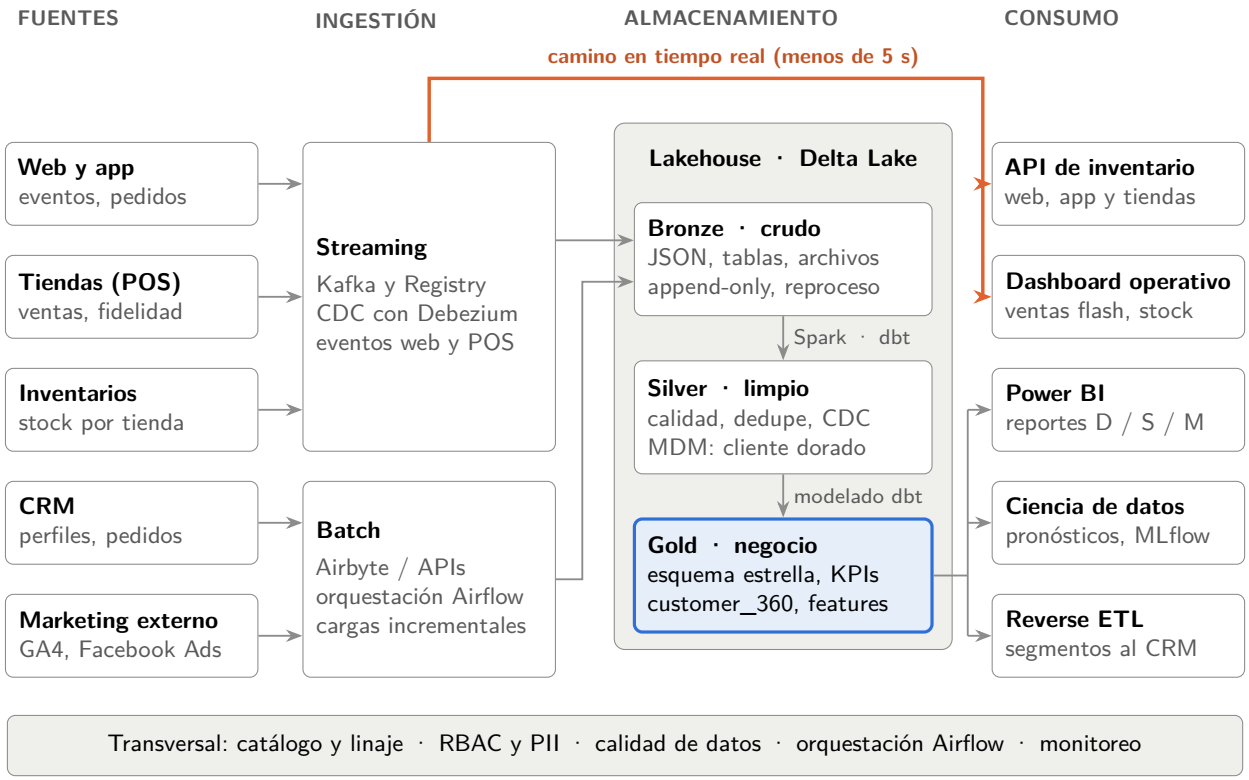


Figura 1: Arquitectura de datos de Yachay-Shop: 5 fuentes, 2 caminos de ingestión y 3 capas de almacenamiento.

Tabla 4: Capas de la arquitectura

Capa	Función	Componentes de referencia
Fuentes	Sistemas operativos y externos que generan los datos	Web/app, POS, CRM, inventarios, GA4, Facebook Ads
Ingestión	Captura de datos en streaming y en batch	Kafka, Schema Registry, Debezium (CDC), Airbyte, Airflow
Almacenamiento	Repositorio único en formato abierto, por capas	Object storage + Delta Lake (Bronze, Silver, Gold)
Procesamiento	Limpieza, unificación, agregación y cálculo en tiempo real	Spark, Flink, dbt
Servicio y consumo	Exposición de datos a personas y aplicaciones	SQL warehouse, Power BI, notebooks, MLflow, API de inventario, reverse ETL
Transversal	Gobierno, seguridad, calidad y operación	Unity Catalog, Great Expectations, monitoreo y alertas

5. Métodos de ingestión por fuente

Cada fuente entra por el método que coincide con su latencia: los datos operativos que cambian en segundos llegan por eventos o CDC a Kafka, y los que cambian a diario llegan por cargas batch programadas. Todo aterriza primero, sin modificar, en la capa Bronze.

Tabla 5: Ingestión por fuente de datos

Fuente	Método	Herramienta	Modo	Destino
Web y app: clickstream	SDK de tracking envía eventos JSON a un collector HTTP que publica en Kafka	Snowplow / Segment + Kafka	Streaming	`web.events` → Bronze
Web y app: pedidos	Eventos de dominio (creado, pagado, cancelado) publicados por el backend	Kafka producer (outbox pattern)	Streaming	`orders` → Bronze
Web y app: perfiles	CDC sobre la base de datos de usuarios	Debezium + Kafka Connect	Streaming (CDC)	`cdc.users` → Bronze
Tiendas (POS)	Cada POS publica ventas y uso de fidelización; sin conexión almacena y reenvía (*store-and-forward*)	Agente edge + Kafka / MQTT	Streaming (micro-lotes)	`pos.sales` → Bronze
Inventarios	CDC sobre tablas de existencias y movimientos	Debezium + Kafka Connect	Streaming (CDC)	`cdc.inventory` → Bronze
CRM	Extracción incremental por `updated_at` o API del CRM	Airbyte / Fivetran + Airflow	Batch (horario o diario)	Bronze `crm/`
Google Analytics	Exportación vía GA4 Data API o export nativo	Airbyte + Airflow	Batch diario	Bronze `marketing/ga4/`
Facebook Ads	Marketing API (insights por campaña, conjunto y anuncio)	Airbyte + Airflow	Batch diario u horario	Bronze `marketing/meta_ads/`
No estructurados	Carga de archivos a object storage con eventos de notificación	Object storage + funciones de eventos	Batch / por evento	Bronze `unstructured/`

Principios de ingestión:

- **CDC en lugar de consultas masivas** sobre sistemas operativos: no carga las bases de producción y captura *inserts*, *updates* y *deletes*.
- **Schema Registry** (Avro/Protobuf) en todos los tópicos Kafka para validar contratos de datos entre productores y consumidores.
- **Idempotencia**: cada evento lleva `event_id` y marca de tiempo de origen; los duplicados se eliminan en Silver.
- **Retención en Kafka** de 7 días como búfer para reprocesar ante fallos.
- **Ingestión incremental** en batch con *watermarks* por fuente, nunca cargas completas diarias.

6. Transformación y unificación de datos

Los datos se refinan en tres capas (*medallion*): Bronze conserva lo crudo, Silver limpia y unifica identidades, y Gold publica modelos de negocio listos para consumir. Cada capa es reprocesable desde la anterior.

Tabla 6: Capas del modelo medallion

Capa	Contenido	Transformaciones	Usuarios
Bronze (raw)	Copia fiel de cada fuente, *append-only*, con metadatos de ingestión (`_source`, `_ingested_at`)	Ninguna sobre el contenido; particionado por fecha de ingestión	Ingeniería de datos, auditoría
Silver (conformed)	Entidades limpias: cliente, producto, tienda, pedido, evento, inventario	Pasos 1–7 (sección 6.1)	Ingeniería y ciencia de datos
Gold (curated)	Modelos dimensionales, *marts*, features de ML, agregados	Joins de negocio, KPIs, agregaciones, SCD	Analistas, Power BI, ML, APIs

6.1 Pasos de transformación Bronze → Silver

1. **Parseo y aplanado**: el JSON del clickstream y de las APIs de marketing se convierte en columnas tipadas; estructuras anidadas (ítems del pedido) pasan a tablas hijas.
2. **Validación de esquema y calidad**: tipos, nulos obligatorios, rangos (precio > 0, cantidad ≥ 0). Los registros que fallan van a una tabla de cuarentena.
3. **Deduplicación** por `event_id` o clave natural más marca de tiempo.
4. **Estandarización**: zona horaria (UTC, con columna local America/Guayaquil), moneda (USD), códigos de país y canal, normalización de emails y teléfonos.
5. **Aplicación de CDC**: los cambios de inventario, usuarios y CRM se consolidan con `MERGE` para obtener el estado actual y conservar historial.
6. **Mapeo de llaves maestras**: SKU web, código POS y código de inventario se mapean a un `product_id` único; igual para tiendas y almacenes.
7. **Enmascaramiento de PII**: emails, teléfonos y documentos se tokenizan o hashean para usos analíticos.

6.2 Resolución de identidad (Vista 360)

La Vista 360 depende de reconocer al mismo cliente en todos los canales. Un proceso de **Master Data Management (MDM)** en Silver asigna un `golden_customer_id`:

- **Coincidencia determinística**: misma cuenta, email, teléfono, tarjeta de fidelización o documento de identidad.
- **Coincidencia probabilística**: nombre, dirección y dispositivo con puntaje de similitud, para compras como invitado.
- **Unión de sesiones anónimas**: el `anonymous_id` del navegador o app se vincula al cliente cuando inicia sesión o usa su tarjeta.
- **Tabla puente** `customer_identity_map` versionada, para auditar y corregir fusiones.

6.3 Herramientas

- **dbt** para transformaciones SQL en Silver y Gold, con pruebas de calidad, documentación y linaje.

- **Spark Structured Streaming / Flink** para las transformaciones del camino en tiempo real.
- **Airflow** para orquestar dependencias y horarios de los *pipelines* batch.

7. Almacenamiento y modelo de datos

Todo el almacenamiento analítico vive en *object storage* en formato Parquet con tablas Delta; solo el estado de inventario en línea usa además un almacén de baja latencia para servir a los canales.

7.1 Almacenamiento según tipo de dato

Tabla 7: Almacenamiento por tipo de dato

Tipo	Ejemplos	Formato	Dónde se guarda
Estructurado	Pedidos, POS, inventario, CRM	Delta (Parquet columnar)	Silver y Gold, tablas con esquema
Semiestructurado	Clickstream, respuestas de APIs de marketing	JSON crudo en Bronze; Delta tipado en Silver	Bronze conserva el JSON original
No estructurado	Reseñas, imágenes, tickets, logs	Archivos originales + metadatos en Delta	Bronze; texto procesado (sentimiento, embeddings) en Silver/Gold
Estado en tiempo real	Disponibilidad por SKU y tienda	Clave-valor	Redis / DynamoDB / Cosmos DB

7.2 Organización física

- **Particionado** por fecha de evento (y canal en clickstream); **Z-order / clustering** por `product_id` y `customer_id` en Gold.
- **Compactación** periódica de archivos pequeños generados por el streaming (`OPTIMIZE`).
- **Time travel** de 30 días para auditoría y recuperación; `VACUUM` controlado.
- **Ciclo de vida**: Bronze en almacenamiento caliente 90 días y luego en capa fría; Silver y Gold siempre en caliente.

7.3 Modelo dimensional de la capa Gold

La capa Gold sigue un **esquema estrella** (Kimball) con dimensiones conformadas compartidas por todos los *marts*.

Tabla 8: Tablas principales de la capa Gold

Tabla	Tipo	Grano	Uso principal
`fact_sales`	Hecho	Una línea de venta (todos los canales)	Ventas, márgenes, reportes
`fact_inventory_snapshot`	Hecho	Producto, ubicación y día	Rotación, quiebres de stock
`fact_web_sessions`	Hecho	Una sesión web/app	Embudo de conversión
`fact_campaign_performance`	Hecho	Campaña, anuncio y día	Costo, clics, conversiones, ROAS
`dim_customer`	Dimensión (SCD 2)	Cliente dorado por versión	Vista 360, segmentación
`dim_product`	Dimensión (SCD 2)	Producto por versión	Rendimiento de producto
`dim_store` / `dim_channel`	Dimensión	Tienda o canal	Comparación por canal
`dim_campaign`	Dimensión	Campaña	Atribución
`dim_date`	Dimensión	Día	Reportes diario, semanal, mensual

Sobre este modelo se publica la tabla `customer_360` (un registro por `golden_customer_id`): perfil, canales usados, total comprado, ticket promedio, recencia, frecuencia y valor (RFM), última campaña que lo impactó, productos favoritos y puntaje de *churn*.

8. Procesamiento batch y en tiempo real

Se adopta un enfoque **híbrido tipo Kappa**: el streaming es el camino principal para los datos operativos y el batch complementa con cargas de fuentes diarias y recálculos pesados. Ambos escriben en las mismas tablas Delta, evitando mantener dos lógicas paralelas como en una arquitectura Lambda clásica.

8.1 Camino en tiempo real (*hot path*)

Tabla 9: Casos de uso en tiempo real

Caso de uso	Procesamiento	Latencia	Salida
Inventario en tiempo real	Flink/Spark consume `cdc.inventory`, `pos.sales` y `orders`; stock disponible = existencia − reservas por SKU y ubicación	< 5 s	Almacén clave-valor + API; evento `inventory.updated`
Engagement del cliente	Agregación por ventanas (1 y 5 min) de sesiones, productos vistos y carritos	< 1 min	Silver en streaming + dashboard
Ventas flash y campañas	Ventas por minuto, producto y campaña; alertas de stock bajo	< 1 min	Dashboard operativo y alertas
Detección de anomalías	Reglas sobre picos de devoluciones, pagos fallidos o caídas de conversión	< 1 min	Alertas a operaciones

Sincronización con canales: el servicio de disponibilidad publica cada cambio de stock; web y app leen de la caché/API, y las tiendas reciben el evento `inventory.updated` por suscripción. Así las tres plataformas ven el mismo número en segundos.

Garantías: semántica *exactly-once* con *checkpoints*, manejo de eventos tardíos con *watermarks* (por ejemplo, 10 minutos para POS que reenvían tras desconexión) y autoescalado de consumidores según el retraso (*lag*) de Kafka.

8.2 Camino batch (*cold path*)

Tabla 10: Procesos batch

Proceso	Frecuencia	Descripción
Ingesta CRM y marketing externo	Diario (horario para Facebook Ads en campaña)	Cargas incrementales a Bronze y transformación a Silver
Construcción de la capa Gold	Diario, antes de las 06:00	dbt reconstruye hechos y dimensiones de forma incremental
MDM / resolución de identidad	Diario	Recalcula coincidencias y actualiza `customer_identity_map`
Agregados semanales y mensuales	Semanal / mensual	Snapshots de cierre para reportes oficiales
Entrenamiento de modelos	Semanal	Pronóstico de demanda, churn, segmentación
Mantenimiento	Diario / semanal	Compactación, vacuum, estadísticas

Airflow orquesta el camino batch con dependencias explícitas, reintentos, SLAs y alertas ante fallos.

9. Consumo: BI, reportes y analítica predictiva

La capa Gold es la única fuente para el consumo; una **capa semántica** define una sola vez cada métrica (ventas netas, margen, ROAS, CAC, LTV) para que todos los reportes den el mismo número.

Tabla 11: Consumidores de datos

Consumidor	Acceso	Datos	Ejemplos
Gerencia y analistas	Power BI sobre SQL warehouse	Marts Gold	Reportes diarios, semanales y mensuales
Operaciones y logística	Dashboard en tiempo real	Tablas streaming	Stock por tienda, ventas flash, alertas
Marketing	Power BI + notebooks	`fact_campaign_performance`, `customer_360`	ROAS, atribución, segmentos para retargeting
Ciencia de datos	Notebooks, feature store	Silver y Gold	Pronóstico, churn, recomendación
Aplicaciones	APIs de datos / reverse ETL	`customer_360`, scores, stock	Recomendaciones, segmentos al CRM

9.1 Eficacia del marketing

Las sesiones y pedidos se enlazan con campañas mediante parámetros UTM, IDs de clic (`gclid`, `fbclid`) y el `golden_customer_id`. Con ello se calculan:

- **ROAS y CPA** por campaña, anuncio y canal (costo de Google/Facebook frente a ventas atribuidas).
- **Atribución** de último clic y multitáctil (lineal o por decaimiento temporal).
- **Impacto en tiendas físicas**: ventas POS con tarjeta de fidelización de clientes expuestos a la campaña online.

9.2 Pronósticos y analítica predictiva

Tabla 12: Modelos predictivos propuestos

Modelo	Técnica sugerida	Entradas	Uso
Demanda por SKU y tienda	Prophet, SARIMA o LightGBM	Ventas históricas, calendario, promociones	Reposición, ventas flash
Ventas agregadas	Series temporales jerárquicas	`fact_sales` por día y canal	Presupuesto, metas
Churn de clientes	Regresión logística, random forest	RFM, engagement, quejas	Campañas de retención
Segmentación	K-means sobre RFM	`customer_360`	Marketing dirigido
Recomendación	Filtrado colaborativo	Interacciones y compras	Web y app

Los modelos se registran y versionan en **MLflow**, y sus predicciones se escriben como tablas Gold para que Power BI las muestre junto a los datos reales.

10. Gobierno, seguridad, calidad y observabilidad

Un catálogo central (Unity Catalog o equivalente) es el punto único de control: registra cada tabla, su dueño, su linaje y quién puede acceder.

Tabla 13: Medidas de gobierno y operación

Área	Medidas
Catálogo y linaje	Registro automático de tablas; linaje de punta a punta (fuente → Bronze → Silver → Gold → reporte); glosario de negocio
Control de acceso	RBAC por capa y dominio; seguridad a nivel de fila (un gerente ve solo su tienda) y de columna
Datos personales	Clasificación de PII, enmascaramiento dinámico, tokenización; cumplimiento de la LOPDP (consentimiento, derecho de supresión)
Cifrado	En reposo (claves en un KMS) y en tránsito (TLS)
Calidad de datos	Pruebas dbt y Great Expectations: unicidad, nulos, rangos, integridad referencial, frescura; cuarentena
Contratos de datos	Esquemas versionados en Schema Registry; cambios incompatibles bloqueados
Observabilidad	Lag de Kafka, duración y fallos de pipelines, frescura por tabla; alertas por SLA
Auditoría	Logs de acceso y consultas; *time travel* para reconstruir estados
Costos	Etiquetas por dominio, apagado automático de clusters inactivos, monitoreo de consumo

Roles: un equipo de plataforma de datos opera la infraestructura; cada dominio (ventas, marketing, inventario) es dueño de la calidad de sus datos en Gold (*data stewards*).

11. Escalabilidad

La arquitectura escala horizontalmente en cada capa porque separa almacenamiento de cómputo y desacopla productores de consumidores mediante Kafka.

Tabla 14: Estrategias de escalado

Componente	Estrategia	Ante una venta flash
Kafka	Más particiones (clave `product_id` o `store_id`) y más brokers	Absorbe el pico como búfer sin perder eventos
Streaming	Paralelismo igual a particiones; autoescalado por lag	Se añaden workers automáticamente
Batch	Clusters efímeros con autoescalado; instancias spot	No compite con el tiempo real
Object storage	Prácticamente ilimitado, pago por uso	Sin cambios
Consultas BI	SQL warehouse serverless con escalado por concurrencia; agregados en Gold	Más clusters en horas pico
Servicio de inventario	Caché clave-valor replicada	Lecturas sin tocar el lakehouse

Prácticas adicionales:

- **Procesamiento incremental**: solo se procesan particiones nuevas o modificadas; el costo crece con el cambio diario y no con el histórico.
- **Infraestructura como código** (Terraform) para replicar entornos y añadir regiones.
- **Modularidad**: agregar una fuente nueva (TikTok Ads, un marketplace) es agregar un conector y un modelo Silver.

- **Evolución hacia Data Mesh**: cada dominio puede publicar sus propios productos de datos sobre la misma plataforma y catálogo.

12. Trazabilidad, implementación y conclusiones

12.1 Necesidades del negocio frente a componentes

Tabla 15: Trazabilidad necesidades–componentes

Necesidad / desafío	Componentes que la resuelven
Silos de datos	Ingestión de las 5 fuentes a un único Lakehouse; dimensiones conformadas; catálogo central
Volumen y variedad	Object storage + Delta; Bronze conserva JSON y archivos; Silver tipa y estructura
Procesamiento en tiempo real	Kafka + CDC (Debezium) + Flink/Spark Streaming + caché de disponibilidad
Vista 360 del cliente	MDM, `dim_customer`, `customer_360`
Inventario en tiempo real	CDC de inventario + eventos POS y pedidos → API de disponibilidad → web, app y tiendas
Eficacia del marketing	Conectores GA4 y Facebook Ads, UTM/gclid/fbclid, `fact_campaign_performance`, atribución
Reportes y pronósticos	Marts Gold, capa semántica, Power BI, modelos de demanda en MLflow
Escalabilidad	Separación almacenamiento/cómputo, particionado, autoescalado, procesamiento incremental

12.2 Hoja de ruta sugerida

1. **Fase 1 – Fundaciones**: plataforma Lakehouse, catálogo, ingestión batch de CRM, POS y marketing; primeros reportes diarios en Power BI.
2. **Fase 2 – Tiempo real**: Kafka, CDC de inventario y pedidos, servicio de disponibilidad para web, app y tiendas.
3. **Fase 3 – Vista 360 y marketing**: MDM, `customer_360`, clickstream completo, atribución de campañas.
4. **Fase 4 – Analítica avanzada**: pronóstico de demanda, churn, recomendaciones y reverse ETL hacia el CRM.

12.3 Riesgos y mitigación

Tabla 16: Riesgos principales

Riesgo	**Mitigación**
Fusiones incorrectas de clientes en MDM	Umbrales conservadores, tabla de identidad versionada y revisión manual
Cambios de esquema en las fuentes	Schema Registry y contratos de datos; Bronze guarda el dato original
Costos de nube crecientes	Procesamiento incremental, clusters efímeros, monitoreo por etiquetas
Cambios en APIs de terceros	Conectores gestionados y alertas de frescura

12.4 Conclusiones

La arquitectura Lakehouse con modelo *medallion* integra en una sola plataforma los cinco sistemas hoy aislados de Yachay-Shop. El camino de streaming garantiza inventario coherente en segundos en todos los canales, mientras el camino batch alimenta reportes y modelos con datos confiables. La resolución de identidad convierte datos dispersos en una Vista 360 del cliente, y el uso de formatos abiertos, cómputo elástico y procesamiento incremental permite crecer en volumen sin rediseñar el sistema.